

Reporte PCA reproducible

Nombre de la persona

Table of contents

1	Nota sobre rutas	1
1.1	Subtitulo	1
2	Introducción	2
3	Cargar paquetes	2
4	Importar datos	3
5	Preparar datos para el PCA	5
6	Ejecutar PCA	6
7	Varianza explicada	6
8	Visualización del PCA	8
9	Guardar la figura	8
10	Interpretación	9
11	Limitaciones	9
12	Conclusión	10

1 Nota sobre rutas

1.1 Subtitulo

En negritas

Este archivo `.qmd` está pensado para guardarse en la carpeta `bin/`.

Por eso, las rutas del código se escriben considerando que el archivo se ejecuta desde `bin/`:

- los datos se leen desde `../data/`;
- las figuras y tablas se guardan en `../results/`.

2 Introducción

En este reporte se presenta un análisis exploratorio de Componentes Principales (PCA) a partir de una tabla de datos biológicos.

Escribe aquí, con tus propias palabras, el objetivo del análisis. Puedes apoyarte en estas preguntas:

- ¿Qué tipo de datos se están analizando?
- ¿Qué representa cada muestra?
- ¿Qué se quiere explorar con el PCA?

3 Cargar paquetes

En esta sección se cargan los paquetes necesarios para importar datos desde Excel, manipular tablas y generar figuras.

Este reporte es una prueba de PCA exploratorio

```
library(readxl)
library(dplyr)
```

```
Attaching package: 'dplyr'
```

```
The following objects are masked from 'package:stats':
```

```
filter, lag
```

```
The following objects are masked from 'package:base':
```

```
intersect, setdiff, setequal, union
```

```
library(ggplot2)
```

```
# Copia aquí el bloque del script donde se cargan los paquetes
```

4 Importar datos

En esta sección se importa el archivo de datos desde la carpeta `data/`.

Como este archivo `.qmd` estará en `bin/`, la ruta debe iniciar con `../data/`.

```
# Recuerda: este script está pensado para ejecutarse desde la raíz del proyecto.
datos <- read_excel("../data/U6_datos_pca.xlsx")
datos
```

```
# A tibble: 900 x 8
```

	muestra	etapa	tratamiento	sitio	TAR	ARF	CO	GA
	<chr>	<chr>	<chr>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	M001	Etapas	control	Norte	4.90	6.75	3.76	5.06
2	M002	Etapas	control	Norte	4.68	6.21	3.24	4.15
3	M003	Etapas	control	Norte	4.84	5.65	3.68	5.5
4	M004	Etapas	control	Norte	4.40	6.60	3.77	4.97
5	M005	Etapas	control	Norte	4.01	6.11	3.72	5.76
6	M006	Etapas	control	Norte	4.86	6.06	5.42	7.58
7	M007	Etapas	control	Norte	7.13	7.03	3.43	4.16
8	M008	Etapas	control	Norte	5.52	3.88	3.10	5.74
9	M009	Etapas	control	Norte	4.86	8.88	2.23	3.18
10	M010	Etapas	control	Norte	3.90	8.16	4.36	4.12

```
# i 890 more rows
```

Después de importar los datos, revisa brevemente la tabla.

```
# Exploración inicial de la tabla.
head(datos)
```

```
# A tibble: 6 x 8
```

	muestra	etapa	tratamiento	sitio	TAR	ARF	CO	GA
	<chr>	<chr>	<chr>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	M001	Etapas	control	Norte	4.90	6.75	3.76	5.06
2	M002	Etapas	control	Norte	4.68	6.21	3.24	4.15

3	M003	Etapa1 control	Norte	4.84	5.65	3.68	5.5
4	M004	Etapa1 control	Norte	4.40	6.60	3.77	4.97
5	M005	Etapa1 control	Norte	4.01	6.11	3.72	5.76
6	M006	Etapa1 control	Norte	4.86	6.06	5.42	7.58

```
dim(datos)
```

```
[1] 900 8
```

```
names(datos)
```

```
[1] "muestra"      "etapa"        "tratamiento" "sitio"        "TAR"
[6] "ARF"          "CO"           "GA"
```

```
str(datos)
```

```
tibble [900 x 8] (S3: tbl_df/tbl/data.frame)
 $ muestra      : chr [1:900] "M001" "M002" "M003" "M004" ...
 $ etapa       : chr [1:900] "Etapa1" "Etapa1" "Etapa1" "Etapa1" ...
 $ tratamiento: chr [1:900] "control" "control" "control" "control" ...
 $ sitio       : chr [1:900] "Norte" "Norte" "Norte" "Norte" ...
 $ TAR         : num [1:900] 4.91 4.68 4.84 4.4 4.01 ...
 $ ARF         : num [1:900] 6.75 6.21 5.65 6.6 6.11 ...
 $ CO          : num [1:900] 3.76 3.24 3.68 3.77 3.72 ...
 $ GA          : num [1:900] 5.06 4.15 5.5 4.97 5.76 ...
```

Escribe aquí una breve descripción de la tabla:

- ¿Cuántas filas tiene?
- Tiene 900 fila
- ¿Cuántas columnas tiene?
- Tiene 4, que son los genes
- ¿Qué columnas corresponden a metadatos?

Son las columnas de muestra, sitio, tratamiento y etapa

- ¿Qué columnas numéricas se usarán para el PCA?

Los 4 genes

5 Preparar datos para el PCA

Antes de ejecutar el PCA, separamos los metadatos de las variables numéricas.

```
# Separar columnas de metadatos.
metadatos <- datos %>%
  select(muestra, etapa, tratamiento, sitio)

# Seleccionar variables numéricas para el PCA.
genes <- c("TAR", "ARF", "CO", "GA")

datos_pca <- datos %>%
  select(all_of(genes))
datos_pca
```

```
# A tibble: 900 x 4
   TAR    ARF    CO    GA
<dbl> <dbl> <dbl> <dbl>
1  4.90  6.75  3.76  5.06
2  4.68  6.21  3.24  4.15
3  4.84  5.65  3.68  5.5
4  4.40  6.60  3.77  4.97
5  4.01  6.11  3.72  5.76
6  4.86  6.06  5.42  7.58
7  7.13  7.03  3.43  4.16
8  5.52  3.88  3.10  5.74
9  4.86  8.88  2.23  3.18
10 3.90  8.16  4.36  4.12
# i 890 more rows
```

Explica brevemente:

- ¿Qué objeto contiene los metadatos?
La variable llamada metadatos
- ¿Qué objeto contiene las variables numéricas?
- ¿Por qué no todas las columnas entran al cálculo del PCA?

6 Ejecutar PCA

En esta sección se ejecuta el PCA con la función `prcomp()`.

```
# Ejecutar PCA con variables centradas y escaladas.
pca_resultado <- prcomp(
  datos_pca,
  center = TRUE,
  scale. = TRUE
)

# Revisar estructura general del resultado.
str(pca_resultado)
```

```
List of 5
 $ sdev      : num [1:4] 1.597 0.915 0.654 0.431
 $ rotation: num [1:4, 1:4] 0.5227 0.3361 0.571 0.5365 0.0479 ...
 ..- attr(*, "dimnames")=List of 2
 .. ..$ : chr [1:4] "TAR" "ARF" "CO" "GA"
 .. ..$ : chr [1:4] "PC1" "PC2" "PC3" "PC4"
 $ center   : Named num [1:4] 8.84 7.56 6.02 7.18
 ..- attr(*, "names")= chr [1:4] "TAR" "ARF" "CO" "GA"
 $ scale     : Named num [1:4] 2.92 2.01 1.65 1.73
 ..- attr(*, "names")= chr [1:4] "TAR" "ARF" "CO" "GA"
 $ x         : num [1:900, 1:4] -2.28 -2.88 -2.37 -2.42 -2.35 ...
 ..- attr(*, "dimnames")=List of 2
 .. ..$ : NULL
 .. ..$ : chr [1:4] "PC1" "PC2" "PC3" "PC4"
 - attr(*, "class")= chr "prcomp"
```

Explica brevemente qué indican los argumentos `center = TRUE` y `scale. = TRUE`.

7 Varianza explicada

En esta sección se calcula qué porcentaje de variación explica cada componente principal.

```
# Calcular la varianza explicada por cada componente principal.
varianza <- pca_resultado$sdev^2
varianza_explicada <- varianza / sum(varianza)
```

```

tabla_varianza <- data.frame(
  componente = paste0("PC", seq_along(varianza_explicada)),
  varianza_explicada = varianza_explicada,
  porcentaje = varianza_explicada * 100
)

```

```
tabla_varianza
```

```

  componente varianza_explicada porcentaje
1         PC1          0.63738082    63.738082
2         PC2          0.20942028    20.942028
3         PC3          0.10682534    10.682534
4         PC4          0.04637357     4.637357

```

```
# Guardar porcentajes para etiquetas de los ejes.
```

```
pc1 <- round(tabla_varianza$porcentaje[1], 1)
```

```
pc2 <- round(tabla_varianza$porcentaje[2], 1)
```

```
# Extraer coordenadas de las muestras en el espacio del PCA.
```

```
pca_scores <- as.data.frame(pca_resultado$x)
```

```
# Agregar metadatos a las coordenadas del PCA.
```

```
pca_scores <- bind_cols(metadatos, pca_scores)
```

```
head(pca_scores)
```

```
# A tibble: 6 x 8
```

```

  muestra etapa  tratamiento sitio  PC1    PC2    PC3    PC4
  <chr>   <chr>   <chr>      <chr> <dbl> <dbl> <dbl> <dbl>
1 M001   Etapa1 control    Norte -2.28  0.337  0.212  0.0366
2 M002   Etapa1 control    Norte -2.88  0.357 -0.0924 -0.0667
3 M003   Etapa1 control    Norte -2.37 -0.237  0.189  0.206
4 M004   Etapa1 control    Norte -2.42  0.283  0.312 -0.0320
5 M005   Etapa1 control    Norte -2.35 -0.106  0.559  0.239
6 M006   Etapa1 control    Norte -1.05 -0.738  0.970  0.148

```


Escribe aquí una interpretación breve:

- ¿Qué porcentaje explica PC1?
- ¿Qué porcentaje explica PC2?
- ¿Cuánto explican juntas PC1 y PC2?

8 Visualización del PCA

En esta sección se construye una figura del PCA usando ggplot2.

```
pca_etapa <- ggplot(pca_scores, aes(x = PC1, y = PC2, color = etapa)) +  
  geom_point(size = 1.8, alpha = 0.45) +  
  labs(  
    title = "PCA exploratorio coloreado por etapa",  
    x = paste0("PC1 (", pc1, "%)"),  
    y = paste0("PC2 (", pc2, "%)"),  
    color = "Etapa"  
  ) +  
  theme_minimal()  
  
pca_etapa
```



```
# Copia aquí el bloque donde se construye la figura principal del PCA
```

9 Guardar la figura

En esta sección se guarda la figura generada en la carpeta **results/**.

Como este archivo `.qmd` estará en `bin/`, la ruta debe iniciar con `../results/`.

```
# Copia aquí el bloque donde se guarda la figura con ggsave()
```

10 Interpretación

Escribe aquí una interpretación breve del PCA.

Puedes apoyarte en estas preguntas:

- ¿Qué representa cada punto?
- ¿Qué variable se usó para colorear las muestras?
- ¿Se observa separación entre etapas?
- ¿La separación ocurre principalmente en PC1, PC2 o ambas?
- ¿Hay traslape entre grupos?
- ¿Qué precaución debes mencionar al interpretar el PCA?

Ejemplo de redacción cuidadosa:

El PCA sugiere un patrón de separación parcial entre etapas, principalmente a lo largo de PC1. Sin embargo, el análisis debe interpretarse como exploratorio, ya que la separación visual no equivale por sí sola a una prueba estadística de diferencia entre grupos.

11 Limitaciones

Menciona al menos una limitación del PCA.

Puedes considerar:

- El PCA es exploratorio.
- No prueba diferencias significativas.
- Puede verse influido por valores extremos.
- La interpretación depende de la preparación de los datos.
- En datos transcriptómicos reales suelen requerirse pasos previos de normalización o transformación.

12 Conclusión

Escribe dos o tres líneas para cerrar el reporte.

Puedes responder:

- ¿Qué aprendiste del patrón observado?
- ¿Qué información adicional sería útil para continuar el análisis?
- ¿Qué análisis complementario podría realizarse después?