

Estadística

Si quieres demostrar algo absurdo toma un montón de datos, tortúralos hasta que digan lo que quieres demostrar, y a la confesión así obtenida llámale "estadísticas".

(Darrel Huff, *How to lie with statistics*)


¿Porque usar R para análisis estadísticos?



Posee un amplio catálogo de pruebas estadísticas

Manipulación completa de parámetros

Resultados claros y concisos



Limpieza de datos

- Importar datos
- Explorar datos
- Necesidad de unir bases; filtrar o seleccionar datos

La limpieza de datos:

- Proceso muy tardado, pero sumamente importante
- Facilita las tareas de análisis de estos




Consideraciones.....

Hay que ser ordenados desde el primer momento



1. Nombres sin espacios, y jamás inicio con numero
2. Nombres cortos
3. No símbolos prohibidos
4. Valores faltantes con 0 o NA
5. Buena estructuración al llenar un dataframe



Acomodo de datos

nombre	tratamiento A	tratamiento B
Jose Lopez Alaman	0	2
Miguel Sanchez Perez	16	11
Lucia Carrillo Santana	3	1



	Jose Lopez Alaman	Miguel Sanchez Perez	Lucia Carrillo Santana
tratamiento A	0	16	3
tratamiento B	2	11	1

Acomodo de datos

nombre	tratamiento	resultado
Jose Lopez Alaman	A	0
Miguel Sanchez Perez	A	16
Lucia Carrillo Santana	A	3
Jose Lopez Alaman	B	2
Miguel Sanchez Perez	B	11
Lucia Carrillo Santana	B	1

Trabajando con el dataframe U3_2

`head(U3_2)`

A tibble: 6 × 5

	TAR	ARF	CO	GA	Etapas
	<dbl>	<dbl>	<dbl>	<dbl>	<chr>
1	5.1	3.5	1.4	0.2	Etapa1
2	4.9	3	1.4	0.2	Etapa1
3	4.7	3.2	1.3	0.2	Etapa1
4	4.6	3.1	1.5	0.2	Etapa1
5	5	3.6	1.4	0.2	Etapa1
6	5.4	3.9	1.7	0.4	Etapa1



`TARgen`

A tibble: 150 × 3

	Etapas	genes	conteo
	<chr>	<chr>	<dbl>
1	Etapa1	TAR	5.1
2	Etapa1	TAR	4.9
3	Etapa1	TAR	4.7
4	Etapa1	TAR	4.6
5	Etapa1	TAR	5
6	Etapa1	TAR	5.4
7	Etapa1	TAR	4.6
8	Etapa1	TAR	5
9	Etapa1	TAR	4.4
10	Etapa1	TAR	4.9

Operadores

¿?

==	equal
!=	not equal
<	less than
<=	less than or equal
>	greater than
>=	greater than or equal
	or
!	not
%in%	in the set

Ejercicio 1

Agrega la columna ratio al data frame murders con el ratio de asesinatos por 50 mil habitantes. Luego, filtra los que tengan un ratio menor a 0.5 y sean de las regiones “Northeast” y “North Central”. Reporta las columnas state, abb y ratio.

```
state abb  ratio
1    Iowa IA 0.3446742
2    Maine ME 0.4140441
3  Minnesota MN 0.4996300
4 New Hampshire NH 0.1899018
5 North Dakota ND 0.2973575
6 South Dakota SD 0.4912919
7   Vermont VT 0.1598105
```

Medidas de dispersión

- sd: desviación estándar
- quantile: dividir en cuantiles
- min: mínimo valor (observaciones)
- max: máximo valor (observaciones)
- range: min y max

Tamaños de muestra

- dim: número de observaciones y variables
- length: (murders\$total) número de observaciones
- length: (murders) número de variables

- Estadística descriptiva

Summary:

Arroja valores de mediana, promedio, mínimos y máximos y cuartiles

```
> summary(murders)
```

state	abb	region	population	total
Length :51	Length :51	Northeast : 9	Min. : 563626	Min. : 2.0
N.unique :51	N.unique :51	South :17	1st Qu.: 1696962	1st Qu.: 24.5
N.blank : 0	N.blank : 0	North Central:12	Median : 4339367	Median : 97.0
Min.nchar: 4	Min.nchar: 2	West :13	Mean : 6075769	Mean : 184.4
Max.nchar:20	Max.nchar: 2		3rd Qu.: 6636084	3rd Qu.: 268.0
			Max. :37253956	Max. :1257.0

```
>
```

>describe(murders)

mean → promedio

sd → desviación estándar

median → mediana

min / max → valores mínimo y máximo

range → rango (max - min)

skew → asimetría (si está cargado a un lado)

kurtosis → forma de la distribución

se → error estándar

Ejercicio 2:

De los datos de la clase pasada (U3_2), obtén estadísticos descriptivos

**agregar summary de tabla

**agregar grafica de cuartiles

La inferencia estadística es un conjunto de métodos y técnicas que permiten deducir características de una población utilizando datos de una muestra aleatoria.

Principales usos de la estadística inferencial

Investigación Científica: Te ayuda a descubrir si tus resultados representan a toda una población.



Negocios: Toma decisiones clave con datos confiables sobre clientes, productos y empleados.



Política: Haz predicciones electorales y analiza datos de votación con estadísticas.




Salud: Evalúa la eficacia de tratamientos y analiza factores de riesgo para enfermedades.



Toma de Decisiones: En todos los campos, la estadística inferencial es una herramienta poderosa para la toma de decisiones basadas en datos.





Pruebas de hipótesis típicas

Antes de proseguir recordemos los conceptos de prueba de hipótesis:

- 1. Hipótesis nula (H_0): hipótesis que se desea contrastar, describe la conducta *default* del fenómeno de interés.
- 2. Hipótesis alternativa (H_1).
- 3. Estadística de prueba: es una estadística con base en la cuál tomamos la decisión de rechazar o no rechazar. Se calcula considerando la hipótesis nula como verdadera.
- 4. Valor-p: Nivel de significancia alcanzado, probabilidad de que la estadística de prueba sea al menos tan extrema como la observada con los datos si la hipótesis nula es verdadera.

Escenario	H_0 verdadera	H_0 Falsa
Rechazar H_0	Error Tipo 1 (α)	Decisión correcta
No rechazar H_0	Decisión correcta	Error tipo 2 (β)

Prueba T student

Comparación de dos medias (paramétrico)

>*t.test*

Description

Performs one and two sample t-tests on vectors of data.

Usage

```
t.test(x, ...)
```

Default S3 method:

```
t.test(x, y = NULL,  
       alternative = c("two.sided", "less", "greater"),  
       mu = 0, paired = FALSE, var.equal = FALSE,  
       conf.level = 0.95, ...)
```

Parte	Qué decide
x, y	qué datos comparas
alternative	tipo de hipótesis ($\neq$, $<$, $>$)
mu	valor de referencia (x=0)
paired	si son dependientes (distintos tiempos)
var.equal	si varianzas son iguales
conf.level	nivel de confianza (95% o 99%)

Welch Two Sample t-test

data: weight by Diet

 $t = -2.6378$, $df = 201.38$, $p\text{-value} = 0.008995$

alternative hypothesis: true difference in means between group 1 and group 2 is not equal to 0

95 percent confidence interval:

-34.899942 -5.042482

sample estimates:

mean in group 1 mean in group 2

102.6455 122.6167

Un valor t negativo: -2.63 (media muestral del grupo 1 es menor significativamente)

El valor df: el grado de libertad asociado al valor de la prueba t.

El p-value: indica la significación estadística del resultado. El valor p: 0.008, que es inferior a alfa (0,05).

Ejercicio 3

- Realiza una prueba t-student para el dataframe U4_1 del gen ARF y las etapas 2 y 3
- ¿Existen diferencias entre estas dos etapas?
- Realiza una prueba t-student para el dataframe murders y la tasa de asesinatos por cada 100,000 habitantes considerando estados grandes y pequeños (si la poblacion es mayor o menor que la media)
- ¿Los estados grandes tienen una tasa de asesinatos distinta a los pequeños?

Prueba de Mann-Whitney: es el equivalente para la prueba T para dos muestras independientes

No paramétrico

Ejemplo:

****#Prueba de Wilcoxon (Mann Whitney)**

Hide

```
Hombres = c(19, 22, 16, 29, 24)
Mujeres = c(20, 11, 17, 12)
wilcox.test(Hombres, Mujeres)
```

```
Wilcoxon rank sum exact test
```

```
data:  Hombres and Mujeres
W = 17, p-value = 0.1111
alternative hypothesis: true location shift is not equal to 0
```

****#El valor de pvalue es mayor a 0.05, por lo que no se rechaza la H0 nula**

ANOVA


3 o mas grupos

> **aov**

Usage

```
aov(formula, data = NULL, projections =  
FALSE, qr = TRUE,  
     contrasts = NULL, ...)
```

-
- Diferencia entre las dietas: 1 y 3, 1 y 4,



- Pero, no se considero el cambio del peso a lo largo del tiempo.

Ayno



Test de Friedman

Comparación de 3 o más variables= equivalente a ANOVA

Usage

```
friedman.test(y, ...)
```

```
## Default S3 method:
```

```
friedman.test(y, groups, blocks, ...)
```

El test de Friedman se utiliza como alternativa no paramétrica al ANOVA de medidas repetidas cuando no se cumplen los supuestos de normalidad. Es adecuado para analizar cambios en mediciones repetidas dentro de los mismos sujetos.

Prueba de Chi cuadrada (Pearson)

Para variables categóricas

PRUEBAS NO PARAMÉTRICAS

1. Para determinar si las frecuencias observadas dentro de cada categoría se ajustan a las frecuencias esperadas

Prueba de Chi cuadrada de bondad de ajuste

		genotipo	Frecuencia esperada	Frecuencia observada
A	A	AA	25	20
	a	Aa	50	66
a	A	Aa	25	14
	a	aa		

2. Para determinar si en categorías combinadas, las frecuencias observadas dependen de la interacción entre los factores que definen las categorías

Prueba de Chi cuadrada de Independencia

	PRI	PAN	PRD
Hombre	20	33	47
Mujer	28	34	42

3. Para determinar si la proporción de frecuencias observadas en las categorías de una población, presentan la misma proporción en otras poblaciones

Prueba de Chi cuadrada de Homogeneidad

	Tipo sanguíneo			
	O	A	B	AB
Población 1	771	91	85	53
Población 2	803	82	89	26
Población 3	698	113	119	70
Población 4	790	61	88	61

Usage

```
chisq.test(x, y = NULL, correct = TRUE,  
           p = rep(1/length(x), length(x)),  
rescale.p = FALSE,  
           simulate.p.value = FALSE, B =  
2000)
```

La prueba de Chi-cuadrada se utiliza para analizar la relación entre variables categóricas mediante la comparación de frecuencias observadas y esperadas.

Datos de interés:

<https://bookdown.org/matiasandina/R-intro/>

<https://rpubs.com/RubenOrtiz/192363>

https://rpubs.com/Joaquin_AR/218466

<https://www.rpubs.com/aafernandez1976/ttest>