


Unidad 5.

Modelos lineales y Mixtos




Regresión lineal


$$\text{Resistencia}_i = \beta_0 + \beta_1 \times \text{Edad}_i + \varepsilon_i$$

donde:

- **Resistencia** es la variable respuesta (dependiente).
- **Edad** es la variable explicativa (independiente).
- β_0 es el intercepto.
- β_1 es la pendiente.
- ε_i representa el error aleatorio.

La función `lm` (linear model) de R se usa para ajustar un modelo de regresión lineal simple






Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2627.822	44.184	59.48	< 2e-16 ***
Edad	-37.154	2.889	-12.86	1.64e-10 ***

¿Cómo se pueden interpretar los efectos $\hat{\beta}$?



- Por cada semana que envejezca la soldadura, se espera que la **resistencia promedio** disminuya en 37.154 psi.
- Si la soldadura es nueva ($Edad = 0$), se espera que la **resistencia promedio** sea de 2627.822 psi.

¿Que hace broom?

broom: Convert Statistical Objects into Tidy Tibbles

Description

Convert statistical analysis objects from R into tidy tibbles,

Porque usamos anova y no aov

- La recomendación general es:
- Usa aov() cuando el interés principal sea comparar medias entre grupos.
- Usa lm() cuando tengas covariables continuas, factores o modelos más generales.
- Usa anova(modelo1, modelo2) para comparar modelos anidados ajustados con lm().

anova () : genera una tabla ANOVA

Se usa para **analizar o comparar** modelos ya ajustados.
Puede utilizarse de dos formas principales.

Hay evidencia estadísticamente significativa de que la variable region mejora el modelo.

```
>anova(murd.mod1,murd.mod2)
```

Analysis of Variance Table

Model 1: population/10^6 ~ total

Model 2: population/10^6 ~ total + region

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	49	168.23				
2	46	140.48	3	27.755	3.0295	0.03875 *


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Pero...

La **tasa de homicidios** es más adecuado que usar el número total de homicidios porque los estados tienen poblaciones muy diferentes.

¿Cuántos homicidios ocurren por cada 100,000 habitantes?

Esto permite comparar estados grandes y pequeños en igualdad de condiciones.




```
lm(rate ~ region, data = murders4) #¿La tasa media de asesinatos es igual en las cuatro regiones de EE.UU.?
```

Como `region` es una variable categórica, R crea variables indicadoras (*dummies*) y elige una región como referencia. En este caso, la referencia es **Northeast**

Prueba de Tukey

\$region

	diff	lwr	upr	p adj
South-Northeast	2.5695121	0.1285845	5.0104395	0.0050001
North Central-Northeast	0.3345395	-2.2764	2.9454605	0.9950001
West-Northeast	-0.0140987	-2.5817281	2.5535306	0.9950001
North Central-South	-2.2349726	-4.467505	0.00256	0.0050001
West-South	-2.5836108	-4.7652273	-0.4019943	0.0050001
West-North Central	-0.3486382	-2.719038	2.0217618	0.9950001



Ejercicio 1

De la base de datos CO2

The CO2 data frame has 84 rows and 5 columns of data from an experiment on the cold tolerance of the grass species *Echinochloa crus-galli*.

- Obten un modelo lineal para explicar si hay relacion entre las variables absorción de CO₂ (uptake) en función de la concentración
- Evalua con anova si el modelo se ajusta

Regresión múltiple


- *Datos con varias variables predictoras*
- *Múltiples variables predictoras y una variable de respuesta*

REGRESIÓN LINEAL MÚLTIPLE (MULTIPLE LINEAL REGRESSION)

Técnica estadística para predecir valores de una variable



WALLSTREETEASY



```
lm(biomasa ~ nitrogeno + luz, data = plantas)
```

Intercepto

```
(Intercept) = 8.70478
```

Es la biomasa esperada cuando:

- nitrogeno = 0
- luz = 0

Efecto del nitrógeno

```
nitrogeno = 0.25609
```

Manteniendo constante la cantidad de luz:

Por cada unidad adicional de nitrógeno, la biomasa aumenta en promedio 0.256 unidades.

Efecto de la luz

```
luz = 1.26337
```

Manteniendo constante el nivel de nitrógeno:

Por cada unidad adicional de luz, la biomasa aumenta en promedio 1.263 unidades.

#Ejercicios 2###

#Ajustar tres modelos y compararlos#

```
mod1 <- lm(biomasa ~ nitrogeno, data = plantas)
```

```
mod2 <- lm(biomasa ~ luz, data = plantas)
```

```
mod3 <- lm(biomasa ~ nitrogeno + luz, data = plantas)
```

¿Qué variable explica mejor la biomasa?

¿Mejora el ajuste al incluir ambas variables?

Modelos lineales generalizados

- *Cuando tenemos variables predictoras discreta y continua que no siguen una distribución normal*
- *Evalúan la dependencia entre las variables predictoras y la variable respuesta mediante una función liga o link*
- *Cuando la variable de respuesta es Binomial, también se conoce como Regresión Logística*

Modelos lineales generalizados

Jessica Nathaly Pulzara Mora

13 de noviembre de 2018

En R los modelos lineales generalizados se ajustan usando la función *glm()*. La forma de la función glm es

```
glm(formula, family = familytype(link = linkfunction), data = )
```

Familia	Función de enlace predeterminada
Binomial	(link = “logit”)
Gaussiana	(link = “identity”)
Gamma	(link = “inverse”)
Inversa	(link = “1/mu^2”)
Poisson	(link = “log”)
quasi	(link = “identity”, variance = “constant”)
quasibinomial	(link = “logit”)
quasipoisson	(link = “log”)

¿Qué distribuciones puedo elegir?

- gaussiano: una distribución gaussiana (normal).
- binomial: una distribución binomial para proporciones.
- Poisson: una distribución de Poisson para cuentas.
- Gamma: una distribución gamma para datos continuos positivos.
- Inverse.gaussian: una distribución gaussiana inversa para datos continuos positivos.

MLG

Database:

Dosis

Código

c

d

i

i

Significado

character (texto)

double
(numérico con
decimales)

integer (entero)

integer (entero)

```
col_types = "cdii"
```

Esto le dice a R **qué tipo de datos tiene cada columna**, e
orden:

El efecto de la dosis **no aumenta en línea recta**

Utilizaremos un set de datos de:
toxicidad a distintas dosis de piretroide
trnas-cipemetrín en los capullos de
gusano del tabaco




resistencia al tóxico en función del sexo de la polilla

Determinar LD50

Representamos la probabilidad de morir en función de las covariables sex y ldosis

Hide

```
ggplot(Dosis,aes(x = ldosis, y = probabilidad, color = sex)) +  
  geom_point() +  
  labs(x = "Logaritmo Dosis", y = "Probabilidad de morir")
```



Se genera un vector con la relación de insectos muertos y vivos

Convertirlo a un modelo binomial

```
Yres <- cbind(Dosis$dead,Dosis$alive)
```

```
Yres
```

	[,1]	[,2]
[1,]	1	19
[2,]	4	16
[3,]	9	11
[4,]	13	7
[5,]	18	2
[6,]	20	0
[7,]	0	20
[8,]	2	18
[9,]	6	14
[10,]	10	10
[11,]	12	8
[12,]	16	4

Generamos dos modelos

m1 <- glm(Yres ~ sex + ldosis, family = binomial, data = Dosis_2) sin interaccion entre sexo y dosis
m2 <- glm(Yres ~ sex * ldosis, family = binomial, data = Dosis_2) con interaccion entre sexo y dosis

anova(m1, m2, test = "Chisq")

Analysis of Deviance Table

Model 1: Yres ~ sex + ldosis

Model 2: Yres ~ sex * ldosis

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	9	6.7571			
2	8	4.9937	1	1.7633	p=0.1842>0.05


Deviance (error del modelo)

👉 El modelo con interacción ajusta mejor (menor deviance)

NO hay evidencia estadística suficiente para incluir la interacción.

Se genera el modelo:

```
fit.dosis <- glm(Yres ~ sex + ldosis,  
                family = binomial(link = logit),  
                data = Dosis)  
  
summary(fit.dosis)  
# prob = Probabilidad buscada (LD50) en concentración de insectícida  
predictor <- binomial(link = logit)$linkfun(0.5)  
machos <- exp((predictor+2.372)/1.535)  
hembras <- exp((predictor+3.473)/1.535)  
machos  
hembras  
prob <- seq(0.05,0.95,0.01)  
# Trabajamos con dosis  
predictor <- binomial(link = logit)$linkfun(prob)  
machos <- exp((predictor + 2.372) / 1.535)  
hembras <- exp((predictor + 3.473) / 1.535)  
dosis <- data.frame(prob, machos, hembras)  
ggplot(dosis) +  
  geom_line(aes(x = prob, y = machos), color = "blue") +  
  geom_line(aes(x = prob, y = hembras), color = "red") +  
  scale_x_continuous(breaks = seq(0,1,0.05)) +  
  scale_y_continuous(breaks = seq(0,70,5)) +  
  labs(x = "Probabilidad de muerte", y = "Dosis") +  
  theme_bw()
```




$$\text{logit}(p) = -3.473 + 1.535 \text{ ldosis}$$

Despejando:

$$\text{ldosis} = \frac{\text{logit}(p) + 3.473}{1.535}$$

Cuanto aumenta la muerte con aumento de dosis



Modelos lineales generalizados mixtos

- De manera similar a lo anterior, evalúa el efecto de una variable predictora sobre una variable de respuesta
- Sirven para evaluar datos en los que existen *medidas repetidas*
- Estos modelos contemplan el error intra grupo, por ejemplo, para observaciones temporales sobre el mismo individuo, observaciones realizadas por el mismo individuo (efectos aleatorios anidados), diseños aleatorizados donde se cambia el orden pero el individuo se evalúa más de una vez (efectos aleatorios cruzados)

```
glmm.CO2 <- lmer(uptake ~ conc + Type + Treatment +  
  (1 | Type / Plant),  
  data = CO2,  
  REML = TRUE)
```

Esto significa:

- `conc` → efecto continuo (cómo cambia uptake con CO₂)
- `Type` → diferencia entre tipos de planta
- `Treatment` → efecto del tratamiento

Interpretación biológica

No todas las plantas responden igual:

- algunas absorben más CO₂ que otras
- incluso dentro del mismo tipo

La absorción de CO₂ depende principalmente de la concentración, y también del tratamiento, mientras que el tipo de planta tiene un efecto pequeño o no significativo en este modelo.

```
anova(glmmm.CO2)
```

Analysis of Variance Table

	npar	Sum Sq	Mean Sq	F value
conc	1	2284.99	2284.99	63.3785
Type	1	59.23	59.23	1.6428
Treatment	1	630.45	630.45	17.4867

conc

La concentración de CO₂ tiene un efecto muy significativo sobre la absorción.

✓ A mayor F → más evidencia de efecto real

Type

No hay evidencia fuerte de que el tipo de planta cambie la absorción, una vez considerado el modelo.

Treatment

El tratamiento sí afecta la absorción de CO₂.

El paquete lmerTest da valores de p-value

Fixed effects:

	Estimate	Std. Error	df	t value	Pr(> t)
(Intercept)	29.259814	7.098468	76.004348	4.122	9.49e-05 ***
conc	0.017731	0.002227	70.999959	7.961	1.97e-11 ***
TypeMississippi	-12.659524	9.876937	74.611345	-1.282	0.20391
Treatmentchilled	-6.859524	1.640363	9.000018	-4.182	0.00237 **

Para variables numéricas continuas

PRUEBAS PARAMÉTRICAS

1. Objetivo:

Determinar si una Media muestral se ajusta a una Media poblacional/fija

Prueba de t para 1 media

Equivalente

2. Objetivo:

Comparar 2 Medias de poblaciones/tratamientos independientes

Prueba de t para 2 medias independientes

- Con varianzas iguales
- Con varianzas diferentes

PRUEBAS NO PARAMÉTRICAS

1. Objetivo:

Determinar si una Mediana muestral se ajusta a una Mediana poblacional/fija

***Prueba del signo**

*** Prueba de los rangos con signo de Wilcoxon ($n \geq 15$)**

2. Objetivo:

Comparar 2 Medianas de poblaciones/tratamientos independientes

Prueba de U Mann Whitney

- <https://epirhandbook.com/es/simple-statistical-tests.html>
- <https://rpubs.com/camilamila/limpieza>
- https://rpubs.com/diegomeza/inferencia_con_R
- <https://rpubs.com/PieroValles/718141>
- Test de Friedman by Joaquín Amat Rodrigo, available under a Attribution 4.0 International (CC BY 4.0) at https://www.cienciadedatos.net/documentos/21_friedman_test

<https://bookdown.org/dietrichson/metodos-cuantitativos/visualizaci%C3%B3n.html>

https://fhernanb.github.io/libro_modelos_mixtos/pac-lme4.html#funci%C3%B3n-lmer

https://bookdown.org/j_morales/librostat/

https://fhernanb.github.io/libro_regresion/rlm.html

~ = option+ñ

Si especificas el modelo como $\text{weight} \sim \text{height} * \text{age}$, esto implica lo siguiente:

- **height:** Es un término principal en el modelo, lo que significa que el efecto de la altura sobre el peso se incluye de manera directa.
- **age:** Es otro término principal en el modelo, lo que significa que el efecto de la edad sobre el peso se incluye de manera directa.
- **height:age:** Este término indica la interacción entre la altura y la edad. En otras palabras, cómo la relación entre altura y peso puede cambiar dependiendo de la edad de la persona, y viceversa.

En términos de expansión, $\text{height} * \text{age}$ es equivalente a $\text{height} + \text{age} + \text{height:age}$. Esto significa que el modelo incluirá:

- El efecto de height solo.
- El efecto de age solo.
- La interacción entre height y age, que captura cómo la relación entre altura y peso varía según la edad.

Ejemplo de interpretación: Supongamos que tienes datos de varias personas con sus respectivas alturas y edades, así como sus pesos correspondientes. Al ajustar un modelo $\text{weight} \sim \text{height} * \text{age}$, podrías determinar cómo la altura influye en el peso, cómo la edad influye en el peso, y además, cómo la relación entre altura y peso puede ser diferente para personas de diferentes edades.

En resumen, $\text{weight} \sim \text{height} * \text{age}$ es una forma compacta y poderosa de especificar un modelo lineal que captura tanto efectos principales como interacciones entre las variables predictoras (en este caso, altura y edad) en relación con la variable de respuesta (peso).

Tú