



# Unidad 8: Expresión Diferencial y Visualización

De la matriz de conteos a la interpretación biológica con R y DESeq2.



# Estudio airway: transcriptoma de células de músculo liso de vía aérea

## Pregunta: ¿Cómo disminuyen la inflamación los glucocorticoides; dexametasona?



### Idea didáctica clave

De los conteos a la interpretación: el análisis estadístico identifica genes; la biología explica su relevancia.



# El Flujo Transcriptómico: ¿Dónde estamos?



*R nos permite ejecutar el análisis; la biología nos permite interpretarlo.*

# Los Datos Base: Matriz y Metadatos



## ¿Qué se midió?

Genes en las filas, Muestras en las columnas.

| Gen        | SRR1039 | SRR1040 |
|------------|---------|---------|
| ENSG000... | 846     | 320     |
| ENSG001... | 12      | 0       |



## ¿Cómo se diseñó el experimento?

Muestras en las filas, Variables biológicas en las columnas.

| Muestra | cell   | dex   |
|---------|--------|-------|
| SRR1039 | N61311 | trt   |
| SRR1040 | N61311 | untrt |

**Regla de oro:** El orden de las columnas en los conteos DEBE coincidir con las filas de los metadatos.




# El Caso airway: De la Pregunta Biológica al R



El diseño experimental se escribe en R,  
pero se decide **exclusivamente** desde la biología.

# El Contenedor Principal: El Objeto DESeqDataSet



Un objeto **unificado** que R utiliza para modelar la dispersión biológica y ejecutar la prueba estadística **(DESeq(dds))**. Evita errores al mantener datos y variables anclados juntos.



# Matriz de Decisión: Conteos Crudos vs. Transformados

## Conteos Crudos (Raw)

|   |   |   |   |   |
|---|---|---|---|---|
| 1 | 2 | 3 | 4 | 5 |
| 0 | 3 | 9 | 4 | 6 |
| 0 | 2 | 4 | 5 | 4 |
| 0 | 0 | 1 | 2 | 0 |

### ¿Para qué se usan?

Prueba estadística de expresión diferencial (DESeq2).

### ¿Por qué?

Preservan la varianza natural y la relación media-dispersión vital para el modelo estadístico.

## Datos Transformados (vst)



### ¿Para qué se usan?

Exploración visual (PCA, Heatmaps).

### ¿Por qué?

Normalizan la varianza para que los genes muy expresados no dominen visualmente los agrupamientos.

# Anatomía de un Resultado: Interpretando la Tabla Final

```
ENSG000001... | baseMean: 846 | log2FoldChange: 2.3 | pvalue: 1e-5 | padj: 0.002
```

## Abundancia

Promedio de conteos en todas las muestras.

## Magnitud


¿Qué tanto cambió? (+ = subió con dexametasona, - = bajó).

## Confiabilidad

Valor p ajustado. ¿Es este cambio significativo o solo ruido estadístico?



# Visualización 1: PCA (Relación entre Muestras)




¿Las muestras tratadas y no tratadas se separan claramente?

¿La variable cell explica la variación en el otro eje?

**El PCA evalúa la relación entre muestras. Si controles y tratamientos están mezclados, el diseño tiene un problema.**



# Visualización 2: MA Plot (Cambio vs. Abundancia)



## Eje Y (Cambio)

Magnitud de la diferencia de expresión.


## Eje X (Abundancia)

Promedio de lectura del gen.

Los genes con conteos bajos tienen alta varianza (ruido). DESeq2 'encoge' (shrinkage) estos valores para evitar falsos positivos.




# Visualización 3: Volcano Plot (Magnitud y Significancia)





# Visualización 4: Heatmap (Patrones de Expresión)



1

## Dato Transformado

Utiliza datos vst escalados (z-score), no conteos crudos.

2

## Agrupamiento (Clustering)

Revela si los genes significativos logran separar perfectamente las muestras tratadas de los controles.

3

## Filtro

Se grafica solo el top de genes (ej. los 30 con menor padj), no el genoma completo.



# Errores Frecuentes: Cuando R se queja

## Las dimensiones no coinciden

Síntoma: Error al crear el DESeqDataSet.

Solución: Verificar con `all(colnames(counts) == rownames(metadata))`. El orden de las muestras es estricto.

## There is no package called DESeq2

Síntoma: Falla `library(DESeq2)`.

Solución: DESeq2 es de Bioconductor, no de CRAN. Usar `BiocManager::install()`.

## Object not found

Síntoma: R no reconoce `vsd` o `res`.

Solución: R distingue mayúsculas. Verificar si el paso anterior se ejecutó correctamente.

## Actividad Práctica: Ajustando los Umbrales

```
1 categoria = case_when(  
2   padj < 0.05 & abs(log2FoldChange) > 1 ~ 'Significativo',  
3   TRUE ~ 'No significativo'  
4 )  
5  
6  
7 categoria = case_when(  
8   padj < 0.05 & abs(log2FoldChange) > 1 ~ 'Significativo',  
9   TRUE ~ 'No significativo'  
10 )  
11 |
```


I



### Preguntas para explorar

¿Qué pasa en el Volcano plot si bajamos el umbral de **padj** a 0.01?

*(Respuesta esperada: Somos más estrictos con los falsos positivos).*



### Preguntas para explorar

¿Qué pasa si subimos el **log2FoldChange** a 2?

*(Respuesta esperada: Solo nos quedamos con cambios biológicos de gran magnitud).*



# La IA como Aliada: Prompt del Día para Código



***Actúa como tutor de R. Me apareció el siguiente error al correr DESeq2: [Pegar error]. Este es mi código: [Pegar código]. Explícame la causa en lenguaje sencillo y dame una solución mínima. No inventes objetos ni columnas.***

## **Lo que SÍ hace la IA:**

Revisar sintaxis, explicar errores, comentar bloques de código.

## **Lo que NO hace la IA:**

Inventar datos biológicos, definir el diseño experimental o interpretar causalidad.



# Cierre: El Flujo Completo



**Un gen estadísticamente significativo no equivale automáticamente a un mecanismo biológico demostrado.**



# Para aprender más...

## Cursos avanzados



<https://www.redmexicanadebioinfor>



INICIO

NOSOTROS

MEMBRESIAS

BECAS

BLOG

CONTACTO



**Encuentro de Bioinformática en México 2026**

**No te pierdas el curso: R para ciencia de datos**

Fecha: 3 al 7 de agosto de 2026  
Modalidad: En línea  
Nivel: básico

**Sinfonía en R**  
Uniando Comunidades por la Bioinformática

Logos: Nodo Nacional de Bioinformática CCG UNAM, Red Mexicana de Bioinformática, CCG, CIENCIAS GENÓMICAS

